

Laporan Praktikum M03 - Optimizer dan Strategi Pelatihan

Identitas Praktikan

Komponen	Isian
Nama	Fadil Prasetyo AlfariZZi
NIM	123450048
Kelas	RC
Modul	M03 - Optimizer dan Strategi Pelatihan
Tanggal praktikum	2026-09-29
Seed/varian individual	48 (empat digit terakhir NIM)
Device	CPU, laptop Windows lewat Local Runner Data Science Workbench

Ringkasan Singkat

Praktikum ini membandingkan SGD, SGD+momentum, dan Adam untuk melatih MLP 784-128-10 pada subset Fashion-MNIST dengan anggaran tetap 5 epoch (470 update pada batch 128). Dari sembilan run terkendali, SGD+momentum $\eta = 0,05$ memperoleh validation loss terendah 0,4029 (akurasi 0,8590) dengan 0,49 detik per epoch, tipis di atas Adam $\eta = 10^{-3}$ (0,4042) yang membutuhkan 0,58 detik per epoch; SGD terbaik ($\eta = 0,1$) tertinggal di 0,4289. Pada konfigurasi itu, CosineAnnealingLR menurunkan validation loss menjadi 0,3744 tanpa menambah update, sedangkan batch 32 justru memburuk (0,7179) dan batch 512 paling cepat (0,31 detik per epoch) dengan loss 0,4281. Berdasarkan validation loss, biaya waktu, dan stabilitas kurva, SGD+momentum $\eta = 0,05$ dengan batch 128 dipilih sebagai model final; evaluasi uji satu kali menghasilkan test loss 0,446 dan akurasi 0,8511.

1. Tujuan dan Hipotesis

1.1 Tujuan

- 1. Memilih optimizer dan learning rate terbaik dari sembilan run terkendali berdasarkan validation loss.
- 2. Mengukur apakah StepLR dan CosineAnnealingLR memperbaiki validation loss pada anggaran 5 epoch yang sama.
- 3. Membandingkan batch 32, 128, dan 512 dari sisi validation loss dan waktu per epoch.

1.2 Hipotesis sebelum eksperimen

Perbandingan	Prediksi	Alasan teknis
Adam $\eta = 10^{-3}$ vs SGD dan SGD+momentum	Adam mencapai validation loss terendah dalam 5 epoch	Langkah adaptif per parameter tidak bergantung skala gradien sehingga cepat turun di awal
Batch 32 vs batch 512	Batch 32 mencapai loss lebih rendah, batch 512 lebih cepat per epoch	Batch 32 mendapat 15 kali lebih banyak update; batch 512 memakai operasi matriks lebih besar

2. Data dan Protokol Eksperimen

2.1 Dataset dan split

Komponen	Nilai
Dataset	Fashion-MNIST (torchvision), citra grayscale 28×28
Jumlah kelas/target	10 kelas pakaian
Train	12.000 contoh (20% dari 60.000 data latih resmi)
Validation	3.000 contoh (5% dari 60.000 data latih resmi)
Test	10.000 contoh (test set resmi)
Cara split	Terstratifikasi dengan <code>train_test_split</code> , <code>random_state = 48</code> (1.200 citra per kelas di train)
Praproses utama	Skala $[0, 1]$, lalu normalisasi dengan mean 0,2863 dan std 0,3534 dari subset latih

Normalisasi dihitung dari subset latih saja, dan test set hanya dipakai satu kali setelah konfigurasi final dipilih dari validation set.

Variabel yang dibuat sama untuk seluruh run: split, seed inisialisasi bobot, urutan batch, arsitektur, loss, jumlah epoch, dan fungsi `jalankan()` yang sama.

Variabel yang sengaja diubah: satu faktor per run, yaitu optimizer dan learning rate (bagian C-D), scheduler, atau batch size (bagian F).

2.3 Lingkungan eksekusi

Python	: 3.13.14
PyTorch	: 2.14.0+cpu
NumPy	: 2.5.3
Device	: CPU
Runtime	: Lokal (Local Runner Data Science Workbench)

2.2 Konfigurasi yang dikendalikan

Komponen	Nilai yang digunakan
Arsitektur dasar	MLP 784 $\rightarrow$ 128 (ReLU) $\rightarrow$ 10, 101.770 parameter
Loss function	Cross-entropy
Optimizer	SGD, SGD+momentum 0,9, Adam
Learning rate	SGD {0,01; 0,1; 0,5}, momentum {0,01; 0,05; 0,1}, Adam { 10^{-4} ; 10^{-3} ; 10^{-2} }; baseline SGD {0,001; 0,1; 1,0}
Batch size	128 (eksperimen batch: 32 dan 512)
Epoch/jumlah update	5 epoch; 470 update pada batch 128
Seed	48
Kriteria pemilihan model	Validation loss terendah
Batas komputasi	19 run di CPU, 1,6-5,8 detik per run

3. Implementasi dan Pemeriksaan Kebenaran

Pemeriksaan	Nilai yang diharapkan	Hasil aktual	Status
Jumlah parameter MLP	101.770	101.770	Lulus
Stratifikasi subset latih	1.200 per kelas	1.200 per kelas	Lulus
Jumlah update batch 32 / 128 / 512	1.875 / 470 / 120	1.875 / 470 / 120	Lulus
Latih ulang final	val loss 0,4029	0,4029	Lulus

Temuan dari pemeriksaan: arsitektur dan split sesuai protokol modul, dan jumlah update per batch size cocok dengan $\lceil 12.000/B \rceil \times 5$. Latih ulang dari seed yang sama mereproduksi validation loss run terpilih, sehingga hasil deterministik untuk seed 48 dan data uji cukup dievaluasi satu kali pada model tersebut.

4. Hasil Eksperimen


4.1 Tabel hasil utama

Run	Perubahan utama	Parameter	Train loss	Val. loss	Val. acc	Waktu/epoch (s)	Catatan
baseline_sgd_lr0.001	SGD, $\eta = 0,001$	101.770	1,3901	1,3345	0,6600	0,487	Turun lambat
baseline_sgd_lr0.1	SGD, $\eta = 0,1$	101.770	0,4013	0,4289	0,8430	0,512	ok
baseline_sgd_lr1	SGD, $\eta = 1,0$	101.770	1,9250	1,9346	0,2843	0,571	Berosilasi
grid_sgd_lr0.01	SGD, $\eta = 0,01$	101.770	0,6042	0,6000	0,7950	0,495	ok
grid_sgd_lr0.1	SGD, $\eta = 0,1$	101.770	0,4013	0,4289	0,8430	0,465	Terbaik SGD
grid_sgd_lr0.5	SGD, $\eta = 0,5$	101.770	0,4852	0,6107	0,7797	0,485	Naik ep. 3, 5
grid_momentum_lr0.01	Momentum, $\eta = 0,01$	101.770	0,3991	0,4298	0,8503	0,507	ok
grid_momentum_lr0.05	Momentum, $\eta = 0,05$	101.770	0,3365	0,4029	0,8590	0,488	Terbaik di grid
grid_momentum_lr0.1	Momentum, $\eta = 0,1$	101.770	0,4282	0,5243	0,8347	0,483	
grid_adam_lr0.0001	Adam, $\eta = 10^{-4}$	101.770	0,5336	0,5325	0,8137	0,582	ok
grid_adam_lr0.001	Adam, $\eta = 10^{-3}$	101.770	0,3620	0,4042	0,8573	0,579	Terbaik Adam
grid_adam_lr0.01	Adam, $\eta = 10^{-2}$	101.770	0,3628	0,4796	0,8423	0,579	Naik ep. 3
final_retrain_momentum_lr0.05	Latih ulang final	101.770	0,3365	0,4029	0,8590	0,511	Test 0,446 / 0,8511
batch_32_momentum_lr0.05	Batch 32	101.770	0,6379	0,7179	0,7393	1,153	Naik epoch 2-3
batch_128_momentum_lr0.05	Batch 128	101.770	0,3365	0,4029	0,8590	0,487	ok
batch_512_momentum_lr0.05	Batch 512	101.770	0,3822	0,4281	0,8503	0,314	ok

Run	Perubahan utama	Parameter	Train loss	Val. loss	Val. acc	Waktu/epoch (s)	Catatan
scheduler_cosine_momentum_lr0.05	Cosine (T_max = 5)	101.770	0,2847	0,3744	0,8687	0,526	Terendah
scheduler_none_momentum_lr0.05	Tanpa scheduler	101.770	0,3365	0,4029	0,8590	0,508	ok
scheduler_step_momentum_lr0.05	StepLR (2 ep, $\gamma = 0,5$)	101.770	0,2915	0,3803	0,8677	0,494	ok

Semua run berstatus ok; tidak ada run yang gagal atau menjadi non-finite.

4.2 Grafik atau visualisasi utama



Gambar 1. Validation loss per epoch untuk pemenang tiap optimizer (batch 128, 5 epoch, split validasi 3.000 citra). Garis biru momentum $\eta = 0,05$, oranye Adam $\eta = 10^{-3}$, hijau SGD $\eta = 0,1$.

Gambar 2. Validation loss per epoch pada momentum $\eta = 0,05$. Kiri: tanpa scheduler vs StepLR (batch 128). Kanan: batch 32 vs 512 tanpa scheduler, dengan jumlah update di legenda.

Temuan dari Gambar 1: momentum dan Adam sudah di bawah 0,51 setelah epoch 1, sedangkan SGD masih 0,671. Kurva momentum naik sesaat di epoch 3 (0,460 ke 0,473) sebelum turun ke 0,4029.

Temuan dari Gambar 2: StepLR menghilangkan kenaikan di epoch 3 (0,404 vs 0,473). Batch 32 naik dari 0,708 ke 0,855 sebelum turun lagi, sedangkan batch 512 turun stabil ke 0,428.

5. Analisis dan Pembahasan

Unsur	Isi
Klaim	Scheduler yang menurunkan learning rate di akhir pelatihan memperbaiki hasil tanpa menambah biaya.
Bukti	Pada 470 update yang sama, validation loss turun dari 0,4029 (tanpa scheduler) menjadi 0,3803 (StepLR) dan 0,3744 (cosine); waktu per epoch tetap 0,49–0,53 detik (Tabel 4.1, Gambar 2).
Penalaran	Dengan $\eta = 0,05$ tetap, momentum masih melompati dasar lembah (kenaikan di epoch 3). Learning rate yang mengecil (0,025 lalu 0,0125 pada StepLR; 0,005 di epoch 5 pada cosine) memperkecil langkah sehingga model mengendap ke minimum.

- Perbandingan dengan hipotesis:** hipotesis optimizer ditolak tipis. Adam $\eta = 10^{-3}$ (0,4042) kalah 0,0013 dari momentum $\eta = 0,05$ (0,4029), selisih yang jauh lebih kecil daripada jarak keduanya ke SGD (0,4289). Hipotesis batch hanya benar untuk kecepatan: batch 512 paling cepat (0,31 vs 1,15 detik per epoch), tetapi validation loss batch 32 justru paling buruk (0,7179 vs 0,4281).
- Run terbaik dan run terburuk:** terbaik cosine (0,3744); terburuk baseline SGD $\eta = 1,0$ (1,9346, akurasi 0,28). Train loss epoch 1 run terburuk 2,48, di atas tebakan acak $\ln 10 \approx 2,30$, dan validation loss naik di epoch 3–4. Langkahnya terlalu besar sehingga melompati minimum. Pola lebih ringan muncul pada SGD $\eta = 0,5$, momentum $\eta = 0,1$, dan Adam $\eta = 10^{-2}$ mulai epoch 3–4.
- Trade-off:** Adam sekitar 20% lebih lambat per epoch (0,58 vs 0,47–0,51 detik) tanpa keuntungan kualitas. Batch 512 1,6 kali lebih cepat daripada batch 128, tetapi validation loss-nya 0,025 lebih tinggi.
- Anomali atau hasil gagal:** batch 32 lebih buruk walaupun mendapat 15 kali lebih banyak update. Learning rate 0,05 dengan momentum 0,9 disetel untuk batch 128; pada batch 32 gradien jauh lebih berderau dengan besar langkah yang sama, sehingga model berosilasi (Gambar 2 kanan).
- Generalisasi:** gap train-validation konfigurasi final kecil (0,337 vs 0,403). Test loss 0,446 sedikit di atas validation loss, wajar karena konfigurasi dipilih dari validation set.

6. Jawaban Pertanyaan Modul

Dijawab pada formulir Pertanyaan Analisis tugas (diperiksa sebagai jawaban-analisis.md) sesuai instruksi Tugas Individu Modul 03.

7. Kesimpulan dan Keterbatasan

7.1 Kesimpulan

Dengan protokol yang setara, SGD+momentum $\eta = 0,05$ dan batch 128 dipilih sebagai konfigurasi final (validation loss 0,4029, test accuracy 0,8511). Adam $\eta = 10^{-3}$ setara kualitasnya (0,4042) tetapi sekitar 20% lebih lambat per epoch. CosineAnnealingLR memperbaiki hasil pada anggaran yang sama (0,3744), dan batch 128 memberi kompromi kualitas-waktu terbaik dibanding batch 32 (0,7179; 1,15 detik per epoch) dan batch 512 (0,4281; 0,31 detik per epoch).

7.2 Keterbatasan

- Satu seed dan subset 12.000 citra membuat selisih kecil seperti momentum vs Adam (0,0013) tidak dapat dibedakan dari variasi antar-seed.
- Anggaran 5 epoch menguntungkan optimizer yang cepat di awal; batch size diuji tanpa menyetel ulang learning rate; waktu diukur di CPU laptop yang berderau sehingga tidak berlaku umum untuk GPU.

7.3 Tindak lanjut

Mengulang tiga pemenang dan scheduler cosine pada 3–5 seed, karena itulah cara paling murah untuk memastikan apakah selisih momentum vs Adam nyata atau hanya variasi seed.

Referensi

- Kingma, D. P., & Ba, J. 2015. Adam: A Method for Stochastic Optimization. ICLR. <https://arxiv.org/abs/1412.6980>
- Loshchilov, I., & Hutter, F. 2017. SGDR: Stochastic Gradient Descent with Warm Restarts. ICLR. <https://arxiv.org/abs/1608.03983>
- Xiao, H., Rasul, K., & Vollgraf, R. 2017. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. <https://arxiv.org/abs/1708.07747>
- Dokumentasi PyTorch 2.14, torch.optim dan torch.optim.lr_scheduler. <https://pytorch.org/docs/stable/optim.html>

Pernyataan Orisinalitas

Saya menyatakan bahwa kode, eksperimen, analisis, dan laporan ini merupakan pekerjaan individual. Semua sumber eksternal, termasuk potongan kode, telah dicantumkan. Saya memahami bahwa kemiripan hasil akibat seed atau data yang sama tidak membenarkan penyalinan notebook maupun analisis.

Nama: Fadil Prasetyo AlfariZZi

Tanggal: 2026-09-29