

Laporan Praktikum M03 - Optimizer dan Strategi Pelatihan

Identitas Praktikan

Komponen	Isian	Komponen	Isian
Nama	Fadil Prasetyo Alfarizzi	Modul	M03 - Optimizer dan Strategi Pelatihan
NIM	123450048	Tanggal praktikum	2026-09-29
Kelas	RC	Seed/varian individual	48 (empat digit terakhir NIM)
Device	CPU (laptop Windows, Local Runner Workbench)	Berkas	M03_123450048.ipynb, M03_123450048_metrics.csv

Ringkasan Singkat

Praktikum ini membandingkan SGD, SGD+momentum, dan Adam untuk melatih MLP 784-128-10 pada subset Fashion-MNIST (12.000 latih, 3.000 validasi) dengan anggaran tetap 5 epoch. Dari sembilan run terkendali, SGD+momentum dengan $\eta = 0,05$ memperoleh validation loss terendah (0,4029, akurasi 0,8590), tipis di atas Adam $\eta = 10^{-3}$ (0,4042), sedangkan SGD terbaik ($\eta = 0,1$) tertinggal di 0,4289. Model final yang dilatih ulang dari seed yang sama mencapai test loss 0,446 dan test accuracy 0,8511. Pada konfigurasi itu, CosineAnnealingLR menurunkan validation loss menjadi 0,3744 tanpa menambah jumlah update, dan batch 128 memberi kompromi terbaik antara kualitas dan waktu. Konfigurasi yang dipilih adalah SGD+momentum $\eta = 0,05$, batch 128, dengan scheduler cosine sebagai perbaikan tambahan.

1. Tujuan dan Hipotesis

Tujuan: (1) memilih optimizer dan learning rate terbaik berdasarkan validation loss dengan protokol yang setara; (2) mengukur pengaruh scheduler pada anggaran epoch yang sama; (3) membandingkan batch size dari sisi kualitas dan waktu.

Perbandingan	Prediksi	Alasan teknis
Adam $\eta = 10^{-3}$ vs SGD/momentum	Adam menang pada 5 epoch	Langkah adaptif per parameter tidak bergantung skala gradien
Batch 32 vs 512	Batch 32 lebih rendah loss-nya, batch 512 lebih cepat per epoch	15 kali lebih banyak update vs operasi matriks lebih besar

2. Data dan Protokol Eksperimen

Komponen	Nilai	Komponen	Nilai
Dataset	Fashion-MNIST (torchvision), 10 kelas	Arsitektur	MLP 784-128(ReLU)-10, 101.770 parameter
Train / Val / Test	12.000 (20%) / 3.000 (5%) dari 60.000 latih; 10.000 test resmi	Loss	Cross-entropy
Cara split	Terstratifikasi, random_state = 48 (1.200 citra per kelas)	Optimizer & η	SGD {0,01; 0,1; 0,5}, momentum 0,9 {0,01; 0,05; 0,1}, Adam { 10^{-4} ; 10^{-3} ; 10^{-2} }
Praproses	Normalisasi mean/std dari subset latih (0,2863 / 0,3534)	Batch / epoch	128 / 5 (470 update)
Pemilihan model	Validation loss terendah	Batas komputasi	19 run, CPU, 1,6–5,8 s per run

Normalisasi dihitung dari data latih saja, dan test set hanya dipakai satu kali setelah konfigurasi final dipilih dari validation set. **Dibuat sama untuk semua run:** split, seed inialisasi, urutan batch, arsitektur, dan fungsi jalankan() yang sama. **Diubah:** optimizer, learning rate, scheduler, atau batch size (satu faktor per run).

Lingkungan: Python 3.13.14, PyTorch 2.14.0+cpu, NumPy 2.5.3, pandas 3.0.5, device CPU, runtime lokal (Local Runner Workbench).

3. Implementasi dan Pemeriksaan Kebenaran

Pemeriksaan	Diharapkan	Hasil aktual	Status
Jumlah parameter MLP	101.770	101.770	Lulus
Stratifikasi subset latih	1.200 per kelas	1.200 per kelas	Lulus
Jumlah update batch 32 / 128 / 512	1.875 / 470 / 120	1.875 / 470 / 120	Lulus
Latih ulang konfigurasi final	val loss = 0,4029	0,4029	Lulus


Temuan: arsitektur dan split sesuai protokol, dan jumlah update per batch size cocok dengan $\lceil 12.000/B \rceil \times 5$. Latih ulang mereproduksi validation loss run terpilih, sehingga hasil deterministik untuk seed 48 dan data uji cukup dievaluasi sekali pada model itu.

4. Hasil Eksperimen


Run	Perubahan utama	Train loss	Val. loss	Val. acc	Grad norm	Waktu/epoch (s)
baseline SGD $\eta=0,001$	learning rate kecil	1,3901	1,3345	0,6600	1,761	0,487
baseline SGD $\eta=1,0$	learning rate besar	1,9250	1,9346	0,2843	1,254	0,571
SGD $\eta=0,01$ / 0,1 / 0,5	grid SGD	0,604 / 0,401 / 0,485	0,6000 / 0,4289 / 0,6107	0,795 / 0,843 / 0,780	1,27 / 1,34 / 1,23	0,49 / 0,47 / 0,49
momentum $\eta=0,01$ / 0,05 / 0,1	grid momentum	0,399 / 0,337 / 0,428	0,4298 / 0,4029 / 0,5243	0,850 / 0,859 / 0,835	1,43 / 1,18 / 1,14	0,51 / 0,49 / 0,48
Adam $\eta=10^{-4}$ / 10^{-3} / 10^{-2}	grid Adam	0,534 / 0,362 / 0,363	0,5325 / 0,4042 / 0,4796	0,814 / 0,857 / 0,842	1,33 / 1,64 / 1,64	0,58 / 0,58 / 0,58
momentum 0,05 + StepLR	scheduler step ($\gamma = 0,5$ tiap 2 epoch)	0,2915	0,3803	0,8677	1,103	0,494
momentum 0,05 + cosine	scheduler cosine (T_max = 5)	0,2847	0,3744	0,8687	1,088	0,526

Run	Perubahan utama	Train loss	Val. loss	Val. acc	Grad norm	Waktu/epoch (s)
momentum 0,05, batch 32	1.875 update	0,6379	0,7179	0,7393	1,643	1,153
momentum 0,05, batch 512	120 update	0,3822	0,4281	0,8503	1,227	0,314

Baseline SGD $\eta = 0,1$ identik dengan run grid. Tidak ada run yang gagal atau non-finite (semua berstatus ok). Model final: **test loss 0,446, test accuracy 0,8511**; pasangan kelas yang paling sering tertukar adalah T-shirt/top dan Shirt (289 kesalahan).



Gambar 1. Validation loss per epoch pemenang tiap optimizer (batch 128, 5 epoch). Momentum dan Adam sudah di bawah 0,51 setelah epoch 1, sedangkan SGD masih 0,67; kurva momentum naik sesaat di epoch 3 (0,460 ke 0,473).



Gambar 2. Kiri: tanpa scheduler vs StepLR; StepLR menghilangkan kenaikan di epoch 3 (0,404 vs 0,473). Kanan: batch 32 naik dari 0,708 ke 0,855 sebelum turun, sedangkan batch 512 turun stabil ke 0,428.

Gambar 1. Validation loss per epoch pemenang tiap optimizer (batch 128, 5 epoch). Momentum dan Adam sudah di bawah 0,51 setelah epoch 1, sedangkan SGD masih 0,67; kurva momentum naik sesaat di epoch 3 (0,460 ke 0,473).

5. Analisis dan Pembahasan

- Hipotesis optimizer hampir tepat.** Adam $\eta = 10^{-3}$ (0,4042) hanya kalah 0,0013 dari momentum $\eta = 0,05$ (0,4029). Selisih ini jauh lebih kecil daripada perbedaan keduanya dengan SGD (0,4289), jadi kesimpulan yang dapat dipegang adalah bahwa momentum dan Adam setara dan sama-sama lebih unggul daripada SGD biasa pada 5 epoch.
- Run terbaik vs terburuk.** Run terburuk adalah SGD $\eta = 1,0$ (val loss 1,9346, akurasi 0,28). Train loss epoch 1 sebesar 2,48 sudah di atas tebakan acak $\ln 10 \approx 2,30$, dan validation loss naik di epoch 3-4. Langkahnya terlalu besar sehingga melompati minimum. Pola lebih ringan terlihat pada SGD $\eta = 0,5$, momentum $\eta = 0,1$, dan Adam $\eta = 10^{-2}$: validation loss naik-turun mulai epoch 3-4.
- Trade-off.** Adam sekitar 20% lebih lambat per epoch ($\approx 0,58$ s vs $0,47$ - $0,51$ s) tanpa keuntungan kualitas. Cosine memperbaiki validation loss 0,0285 tanpa biaya waktu berarti. Batch 512 1,6 kali lebih cepat daripada batch 128, tetapi validation loss-nya 0,025 lebih tinggi.
- Anomali.** Batch 32 lebih buruk daripada batch 512 walaupun mendapat 15 kali lebih banyak update. Learning rate 0,05 dengan momentum 0,9 disetel untuk batch 128; pada batch 32 gradien jauh lebih berderau sementara besar langkahnya sama, sehingga model beresili.
- Generalisasi.** Gap train-validation konfigurasi final kecil (0,337 vs 0,403), dan test loss 0,446 sedikit di atas validation loss karena konfigurasi dipilih dari validation set.

7. Kesimpulan dan Keterbatasan

Kesimpulan. Dengan protokol yang setara, SGD+momentum $\eta = 0,05$ dipilih sebagai konfigurasi final (val loss 0,4029, test accuracy 0,8511), dengan Adam $\eta = 10^{-3}$ sebagai alternatif yang setara namun $\pm 20\%$ lebih lambat per epoch. Scheduler cosine memperbaiki hasil pada anggaran yang sama (0,3744), dan batch 128 memberi kompromi kualitas-waktu terbaik dibanding batch 32 (0,7179, 1,15 s/epoch) dan 512 (0,4281, 0,31 s/epoch).

Keterbatasan. (1) Satu seed dan subset 12.000 citra membuat selisih kecil seperti momentum vs Adam (0,0013) tidak dapat dibedakan dari variasi antar-seed. (2) Anggaran 5 epoch menguntungkan optimizer yang cepat di awal, sehingga peringkat bisa berubah pada pelatihan lebih lama atau data penuh. (3) Batch size diuji tanpa menyetel ulang learning rate, dan waktu diukur di CPU laptop yang berderau, sehingga kesimpulan waktu tidak berlaku umum untuk GPU.

Tindak lanjut. Mengulang tiga pemenang dan scheduler cosine pada 3-5 seed agar selisih momentum vs Adam dapat dinilai dengan rata-rata $\pm$ simpangan baku.

Referensi

- Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. ICLR. <https://arxiv.org/abs/1412.6980>
- Loshchilov, I., & Hutter, F. (2017). SGDR: Stochastic Gradient Descent with Warm Restarts. ICLR. <https://arxiv.org/abs/1608.03983>
- Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST. <https://arxiv.org/abs/1708.07747>
- Dokumentasi PyTorch 2.14 (torch.optim, lr_scheduler). <https://pytorch.org/docs/stable/optim.html>

Pernyataan Orisinalitas

Saya menyatakan bahwa kode, eksperimen, analisis, dan laporan ini merupakan pekerjaan individual. Semua sumber eksternal telah dicantumkan. Saya memahami bahwa kemiripan hasil akibat seed atau data yang sama tidak membenarkan penyalinan notebook maupun analisis.

Nama: Fadil Prasetyo Alfarizzi

Tanggal: 2026-09-29